

Prelucrarea șirurilor de caractere. Funcții. Aplicații.

Responsabili: Responsabili:

- Dorinel Filip (CA 2016-2020) [mailto:ion_dorinel.filip@cti.pub.ro]
- Darius Neațu (CA 2019-2020) [mailto:neatudarius@gmail.com]
- Emil Racec (2012) [mailto:emil.racec@gmail.com]
- Alina Simion (2008) [mailto:alina.g.simion@gmail.com]
- Ștefan Bucur (2006) [mailto:stefan.bucur@gmail.com]

Obiective

În urma parcurgerii acestui laborator studentul va fi capabil:

- să declare și să folosească șiruri de caractere
- să folosească funcțiile de manipulare a șirurilor de caractere din biblioteca string.h

Noțiuni teoretice

Șiruri de caractere

Un **caracter** se declară în C de forma: `char a='a'`; Pentru inițializarea lui, se observă că am pus un caracter între apostroafe.

Un **șir de caractere** presupune practic un vector de caractere, terminat prin caracterul `\0`.

Compilerul folosește în mod implicit această reprezentare, astfel încât cea mai simplă declarație este `char c[]="cuvant"`; Observăm aici folosirea ghilimelelor în locul apostroafelor. Această instrucțiune va alocă un spațiu de 7 octeți pe care va reprezenta șirul de caractere 'cuvant' (care are 6 caractere).

Dacă dorim să alocăm un spațiu de memorie mai mare (pentru a putea folosi variabila pentru a stoca șiruri de caractere mai lungi), putem folosi o declarație de tipul `char c[10] = "cuvant"`; . Astfel am alocat spațiu suficient pentru un șir de 9 caractere.

Deși o inițializare de tipul `char c[6] = "cuvant"`, în care spațiul alocat este egal cu numărul de caractere, nu va determina compilerul să genereze un warning/o eroare, acest lucru poate avea rezultate neașteptate dacă în memorie - la finalul șirului - nu se află (întâmplător) valoarea 0 binar.

Cum s-a prezentat anterior, o variabilă vector conține adresa de început a vectorului (adresa primei componente a vectorului), și de aceea este echivalentă cu un pointer la tipul elementelor din vector. Deci declarațiile de mai jos vor declara fiecare câte un șir de caractere:

```
char a[5];
char *b="unsir";
char *c;
```

Diferența majoră dintre între ele este însă că primele două declarații vor alocă 5 poziții în memorie, pe când ultima nu va alocă nici o zonă de memorie, necesitând să fie ulterior alocată, folosind funcțiile de alocare dinamică (`malloc()`, `calloc()`, `realloc()`), prezentate în laboratorul anterior.

Între prima și a 2-a declarație, diferența este mai subtilă și constă în faptul că declarația `char *b="unsir"` va determina compilerul să plaseze șirul respectiv într-o zonă de memorie asupra căreia nu avem drepturi de scriere, deci orice încercare de a modifica acel șir - pe Linux - va genera, cel mai probabil, o eroare de tipul `segmentation fault`.

Un mic exemplu de citire a unui șir, caracter cu caracter până la întâlnirea caracterului `-`:

```
#include <stdio.h>
#include <string.h>

#define N 30

int main () {
    char str[N], c;
    int n = 0;

    do {
        scanf("%c", &c);
        if (c == '-') {
            break;
        }
        str[n++] = c;
    } while(1);

    str[n] = '\0'; // setam terminatorul de șir
    printf("%s", str);

    return 0;
}
```

Pentru citirea și afișarea unui șir de caractere se poate folosi flagul `'s'` la citirea cu `scanf` sau afișarea cu `printf`. De asemenea biblioteca `stdio.h` definește funcțiile `gets()` și `puts()` pentru lucrul cu șiruri de caractere.

- `gets(zona)` -- citește de la terminalul standard un șir de caractere terminat cu linie nouă (enter).
 - Funcția are ca parametru adresa zonei de memorie în care se introduc caracterele citite.
 - Funcția returnează adresa de început a zonei de memorie.
- `puts(zona)` - afișează la terminalul standard șirul de caractere din zona data ca parametru, până la caracterul terminator de șir (`\0`), în locul căruia va afișa caracterul sfârșit de linie.
 - Funcția are ca parametru adresa zonei de memorie de unde începe afișarea caracterelor.
 - Funcția returnează codul ultimului caracter (diferit de `\0`) din șirul de caractere afișat și `-1` dacă a apărut o eroare.

Funcția `gets()` va citi de la tastatură câte caractere sunt introduse, chiar dacă șirul declarat are o lungime mai mică. Presupunem un șir declarat: `char a[]="unsir"`, care va avea deci 5 caractere. Citind un șir de lungime mai mare ca 5 de la tastatură, în șirul `a`, la afișare vom vedea că s-a reținut tot șirul (nu

doar primele 5 caractere)! . Nimic deosebit până acum. Dar dacă luăm în considerare că citirea caracterelor auxiliare se face în continuare în zona de memorie, ne punem problema ce se va suprascrie?! Raspunsul este: nu se ştie... poate nimic important pentru programul nostru, poate ceva ce îl va bloca sau duce la obţinerea de date eronate.

Pentru a evita aceasta se recomandă utilizarea `fgets()`.

- `fgets(zona, lung_zona, stdin)` -- citeşte de la `stdin` un şir de caractere terminat printr-o linie nouă dacă lungimea lui este mai mică decât `lung_zona` sau primele `lung_zona - 1` caractere în caz contrar. Parametrii sunt: zona de memorie, lungimea maxima admisă a şirului, şi terminalul standard de intrare. În cazul în care şirul dorit are lungime mai mică decât cea maximă, înaintea terminatorului de şir (`\0`), în zona de memorie va fi reţinut şi enter-ul `dat(\n)`.

Funcţii din <string.h>

Pentru manipularea şirurilor de caractere în limbajul C se folosesc funcţii declarate în fişierul <string.h>. Vom încerca să le detaliem puțin pe cele mai des folosite:

strlen()

```
size_t strlen(const char *str);
```

Returnează lungimea unui şir dat ca parametru. (numarul de caractere până la întâlnirea terminatorului de şir: `\0`)

Exemplu:

```
#include <stdio.h>
#include <string.h>

#define N 256

int main () {
    char text[N];
    printf("Introduceti un text: ");
    gets(text);
    printf("Textul are %u caractere.\n", strlen(text));
    return 0;
}
```

Iesire:

```
Introduceti un text: just testing
Textul are 12 caractere.
```

memset()

```
void* memset(void *ptr, int val, size_t num);
```

În zona de memorie dată de pointerul `ptr`, sunt setate primii `num` octeţi la valoarea dată de `val`. Pentru şiruri de caractere - în care fiecare element ocupă 1 octet - aceasta are ca rezultat înlocuirea primelor 'num' valori cu cea dată ca argument.

Funcţia returnează şirul `ptr`.

Exemplu:

```
#include <stdio.h>
#include <string.h>

int main () {
    char str[] = "nu prea vreau vacanta!";
    memset(str, '-', 7);
    puts(str);
    return 0;
}
```

Iesire:

```
----- vreau vacanta!
```

Ca programatori, veţi întâlni adesea situaţii în care `memset` este folosit pentru iniţializarea de vectori de diverse tipuri.

Atunci când scrieţi sau evaluaţi cod care face acest lucru trebuie să aveţi în vedere că `memset` face scrierea valorii primite pe fiecare **octet** (fără a ţine cont de dimensiunea reprezentării tipului de date). Următorul cod arată cum putem folosi `memset` pentru a iniţializa un vector de `int` la 0 folosind `memset`, respectiv care ar fi rezultatul dacă am încerca să iniţializăm vectorul cu o altă valoare:

```
#include <stdio.h>
#include <string.h>

#define SIZE 2

int main(void)
{
    int a[SIZE], b[SIZE], i;
    memset(a, 0, SIZE * sizeof(int));
    memset(b, 5, SIZE * sizeof(int));

    for(i = 0; i < SIZE; i++)
        printf("%d ", a[i]);

    printf("\n");

    for(i = 0; i < SIZE; i++)
        printf("%d ", b[i]);

    return 0;
}
```

Rezultatul este...

```
0 0
84215045 84215045
```

rezultatul neaşteptat de pe a 2-a linie provenind din faptul că fiecare octet al int-urilor a fost setat la 5, şi nu valoarea întregii structuri.

Este de menţionat faptul că utilizarea `memset` în astfel de situaţii **nu** este recomandată.

`memmove()`

```
void* memmove(void *destination, const void *source, size_t num);
```

Copiază un număr de `num` caractere de la sursă, la zona de memorie indicată de destinaţie. Copierea are loc ca şi cum ar exista un buffer intermediar, deci sursa şi destinaţia se pot suprapune. Funcţia nu verifică terminatorul de şir la sursă, copiază mereu `num` bytes, deci pentru a evita depăşirea trebuie ca dimensiunea sursei să fie mai mare ca `num`. Funcţia returnează destinaţia.

Exemplu:

```
#include <stdio.h>
#include <string.h>

int main () {
    char str[] = "memmove can be very useful.....";
    memmove(str + 20, str + 15, 11);
    puts(str);
    return 0;
}
```

Iesire:

```
memmove can be very very useful.
```

`memcpy()`

```
void* memcpy(void *destination, const void *source, size_t num);
```

Copiază un număr de `num` caractere din şirul sursă în şirul destinaţie. Funcţia returnează şirul destinaţie.

Exemplu:

```
#include <stdio.h>
#include <string.h>

#define N 40

int main () {
    char str1[] = "Exemplu";
    char str2[N];
    char str3[N];
    memcpy(str2, str1, strlen(str1) + 1); // + 1 este necesar pentru a copia şi terminatorul de şir
    memcpy(str3, "un sir", 7);
    printf("str1: %s\nstr2: %s\nstr3: %s\n", str1, str2, str3);
    return 0;
}
```

Iesire:

```
str1: Exemplu
str2: Exemplu
str3: un sir
```

`strcpy()`

```
char* strcpy(char *destination, const char *source);
```

Copiază şirul sursă în şirul destinaţie. Şirul destinaţie va fi suprascris. Funcţia asigură plasarea terminatorului de şir în şirul destinaţie după copiere. Funcţia returnează şirul destinaţie.

`strncpy()`

```
char* strncpy(char *destination, const char *source, size_t num);
```

Asemeni cu `strcpy()`, dar în loc de a fi copiată toată sursa sunt copiate doar primele `num` caractere.

Exemplu:

```
#include <stdio.h>
#include <string.h>

#define N 40

int main () {
    char str1[] = "Exemplu";
    char str2[N];
    char str3[N];
    strcpy(str2, str1);
    strncpy(str3, "un sir", 2);
    str3[2] = '\0';
    printf("str1: %s\nstr2: %s\nstr3: %s\n", str1, str2, str3);
    return 0;
}
```

Iesire:

```
str1: Exemplu
str2: Exemplu
```

```
str3: un
```

strcat()

```
char* strcat(char *destination, const char *source);
```

Concatenaza șirul sursă la șirul destinație. Funcția returnează șirul destinație.

Șirul destinație trebuie să aibă suficientă memorie alocată pentru a acomoda șirul rezultat.

strncat()

```
char* strncat(char *destination, const char *source, size_t num);
```

Asemeni cu `strcat()`, dar în loc de a fi concatenată toată sursa sunt concatenate **cel mult** primele *num* caractere din șirul sursa (aceasta putând fii și mai scurt).

Exemplu:

```
#include <stdio.h>
#include <string.h>

#define N 80

int main () {
    char str[N];
    strcpy(str, "ana ");
    strcat(str, "are ");
    strcat(str, "mere ");
    puts(str);
    strncat(str, "si pere si prune", 7);
    puts(str);
    return 0;
}
```

Iesire:

```
ana are mere
ana are mere si pere
```

strcmp()

```
int strcmp(const char *str1, const char *str2);
```

Compară șirul *str1* cu șirul *str2*, verificându-le caracter cu caracter. Valoarea returnată este 0 daca cele șiruri sunt identice, mai mare ca 0 daca *str1* este "mai mare"(alfabetic) și mai mic ca 0 altfel.

Exemplu:

```
#include <stdio.h>
#include <string.h>

#define N 80

int main () {
    char cuv[] = "rosu";
    char cuv_citit[N];
    do {
        printf ("Ghicesc culoarea...");
        gets(cuv_citit);
    } while (strcmp(cuv,cuv_citit) != 0);

    puts("OK");

    return 0;
}
```

În situația în care șirurile au lungimi diferite, ultima comparație se face între \0 și caracterul de pe aceeași poziție din șirul mai lung,

strchr()

```
char* strchr(const char *str, int character);
```

Caută caracterul *character* în șirul *str* și returnează un pointer la *prima* sa apariție sau NULL dacă acesta nu a fost găsit..

strrchr()

```
char* strrchr(const char *str, int character);
```

Caută caracterul *character* în șirul *str* și returnează un pointer la *ultima* sa apariție sau NULL dacă acesta nu există în șir.

strstr()

```
char* strstr(const char *str1, const char *str2);
```

Caută șirul *str2* în șirul *str1* și returnează un pointer la *prima* sa apariție, sau NULL dacă nu a fost găsit.

strdup()

```
char* strdup(const char *str);
```

Realizează un duplicat al șirului *str*, pe care îl și returnează. Spațiul de memorie necesar copiei este alocată dinamic, fiind responsabilitatea noastră să o dealocăm (așa cum am s-a prezentat laboratorul anterior).

Exemplu:

```
#include <stdio.h>
#include <string.h>

#define N 80

int main () {
    char str[N] = "salut", *d;

    d = strdup(str);
    if(d == NULL) {
        printf("Eroare!\n");
        return -1;
    }

    puts(d);
    free(d);

    return 0;
}
```

`strdup(..)` va alocă întotdeauna `strlen() + 1` octeți pentru destinație, indiferent de dimensiunea memoriei alocate pentru sursă.

strtok()

```
char* strtok(char *str, const char *delimiters);
```

Funcția are rolul de a împărți șirul *str* în tokens(subșiruri separate de orice caracter aflat în lista de delimitatori), prin apelarea ei succesivă.

La primul apel, parametrul *str* trebuie să fie un șir de caractere, ce urmează a fi împartit. Apelurile următoare, vor avea în loc de *str*, NULL conținând împărțirea aceluiași șir.

Funcția va returna la fiecare apel un token(un subsir), ignorând caracterele cu rol de separator aflate în șirul de delimitatori. O dată terminat șirul, funcția va returna NULL.

Implementarea curentă din `<string.h>` nu permite folosirea `strtok()` în paralel pe mai mult de un șir.

Exemplu:

```
#include <stdio.h>
#include <string.h>

int main () {
    char str[] = "- Uite, asta e un sir.";
    char *p;
    p = strtok(str, " ,.-");
    /* separa sirul in "tokeni" si afiseaza-i pe linii separate. */
    while (p != NULL) {
        printf("%s\n", p);
        p = strtok(NULL, " ,.-");
    }

    return 0;
}
```

Iesire:

```
Uite
asta
e
un
sir
```

Exercitii laborator CB/CD

Primul exercitiu presupune modificarea/adaugarea de instructiuni unui cod existent pentru a realiza anumite lucruri. In momentul actual programul numara cate cuvinte doar cu litere mici se gasesc intr-un sir de caractere.

ex.c

```
#include <stdio.h>
#include <string.h>
#include <ctype.h>
#include <stdlib.h>

#define SEPARATORS " ,.-"

int count_lowercases_words(char *str)
{
    char *tmp_str = strdup(str);
    unsigned int count = 0;

    if (tmp_str == NULL) {
        printf("Eroare la alocare\n");
        return -1;
    }

    char *word = strtok(tmp_str, SEPARATORS);
    while (word) {
        unsigned int i;

        for (i = 0; i < strlen(word); i++) {
            if (isupper(word[i])) {
                break;
            }
        }

        count++;
    }

    return count;
}
```

```

        if (i == strlen(word)) {
            count++;
        }

        word = strtok(NULL, SEPARATORS);
    }

    free(tmp_str);
    return count;
}

int main(void)
{
    char sentence[] = "Ana are mere, pere si gutui. Gigel nu are nimic.";

    printf("%d\n", count_lowercases_words(sentence));

    return 0;
}

```

Cerinte:

- Sa se numere cate cuvinte au cel putin un caracter din sirul "api".
- Sa se realizeze o functie care intoarce un sir de caractere compus din cuvintele care incep cu litera mare.

Următoarele două probleme vă vor fi date de asistent în cadrul laboratorului.

Checker laborator 10 [https://drive.google.com/drive/folders/1qB6EZLGVubKbuTXMtMue06egH_8fo25M]

Tutorial folosire checker laborator [<https://ocw.cs.pub.ro/courses/programare/checker>]

Exercitii de laborator

1. [2p] Să se citească o succesiune de cuvinte. Să se creeze o funcție: `void ordCresc(char *vectorschar[], int n);` care să ordoneze cuvintele crescător
 - după lungimea acestora.
 - alfabetic
2. [2p] Să se determine dacă o propozitie este palindromă. O propozitie este palindromă daca citită de la prima literă până la ultima are aceeași succesiune ca citită de la ultima literă până la prima. Nu conteaza dacă sunt litere mici sau mari.
Exemplu: ele fac cafele
3. [1p] Folosind funcția `strtok`, citiți un șir de caractere și afișați pe ecran cuvintele sale constitutive.
4. [2p] Folosind funcția `strtok`, citiți un șir de caractere, apoi un cuvânt și afișați pe ecran numărul de apariții al cuvântului în șir.
5. [3p] Folosind funcțiile din `<string.h>` înlocuiți într-un text dat o secvență de caractere cu altă secvență de caractere, date la intrare.

Bonus

1. [3p] Se dă N de la tastatură. Citiți pentru fiecare N numele, prenumele și vârsta elevului respectiv, alocând întreaga memorie în mod dinamic pentru fiecare elev nou (lungimea numelui și a prenumelui se consideră a fi 20 de caractere, iar vârsta se consideră între 0 și 100). Afișați pe ecran, în funcție de opțiunea selectată, lista citită de la tastatură, ordonată în funcție de nume, prenume, respectiv vârstă.

Referințe

- Wikipedia - String(Computer science) [[http://en.wikipedia.org/wiki/String_\(computer_science\)](http://en.wikipedia.org/wiki/String_(computer_science))]
- Wikipedia - C string handling [<http://en.wikipedia.org/wiki/String.h>]

Probleme laborator 14-16 [<https://drive.google.com/open?id=1n-X0kssdqDXF9i73VfMxAb7GZP7CzhT3>]

programare/laboratoare/lab10.txt · Last modified: 2020/10/05 00:38 by darius.neatu